

Exercice : Comprendre l'effet de la similarité entre Q et K sur les poids d'attention

Dans le mécanisme d'attention à produit scalaire, les poids d'attention sont calculés ainsi :

1. Scores bruts : $S = Q \cdot K^T$
2. Mise à l'échelle : $S_scaled = S / \sqrt{d_k}$
3. Softmax : $poids = \text{softmax}(S_scaled)$

Plus le produit scalaire entre un vecteur de requête ($Q[i]$) et un vecteur de clé ($K[j]$) est grand, plus le poids $poids[i, j]$ sera élevé après softmax.

Objectif

Modifier manuellement les matrices Q et K dans le programme fourni pour observer comment des **similarités artificiellement fortes** rendent la distribution des poids très concentrée (quasi "one-hot").

Consignes

1. Repartez du programme de démonstration (celui qui calcule l'attention pas à pas).
2. Remplacez les matrices Q et K calculées par projection par des matrices que vous construisez vous-même.
Par exemple, fixez la dimension $d_k = 3$ et créez :
python

```
# 3 requêtes, 3 clés (pour 3 tokens)

Q = np.array([
    [1.0, 0.0, 0.0], # requête du token 1
    [0.0, 1.0, 0.0], # requête du token 2
    [0.0, 0.0, 1.0] # requête du token 3
])
K = np.array([
    [0.1, 0.1, 0.1], # clé du token 1
```

```
[1.0, 0.0, 0.0], # clé du token 2 ← identique à Q[0]
[0.0, 0.0, 0.1] # clé du token 3
])
```

Ici, $Q[0]$ est identique à $K[1]$ → leur produit scalaire sera grand.

Les autres produits scalaires seront petits (car directions orthogonales ou vecteurs petits).

3. Calculez manuellement (ou à l'aide du programme) les étapes :

- o $\text{scores} = Q \cdot K^T$
- o $\text{scores_scaled} = \text{scores} / \sqrt{d_k}$ (avec $d_k = 3$)
- o $\text{poids} = \text{softmax}(\text{scores_scaled})$

Observez la matrice des poids d'attention.

Quelle est la valeur de $\text{poids}[0, 1]$? Est-elle proche de 1 ?

Les autres poids sur la ligne 0 sont-ils proches de 0 ?

Variante : changez les valeurs pour que ce soit une autre requête (par exemple $Q[1]$) qui s'aligne avec une clé différente.

Question de réflexion

Pourquoi cette propriété (un grand produit scalaire → poids proche de 1) permet-elle à un Transformer entraîné de modéliser des relations sémantiques fortes (par exemple, un verbe qui s'accorde avec son sujet, ou un pronom qui se réfère à un nom) ?

Résultat attendu (avec l'exemple ci-dessus)

- $\text{scores}[0, 1] = 1.0 \cdot 1.0 + 0.0 \cdot 0.0 + 0.0 \cdot 0.0 = 1.0$
- Les autres scores sur la ligne 0 sont faibles (0.1, 0.0).

- Après softmax, `poids[0, 1]` sera très proche de **1.0** (par exemple 0.95), et les deux autres poids proches de 0.02 et 0.03.
- La ligne 0 de la matrice d'attention sera donc **quasi one-hot** sur la colonne 1 (le token 2).